國立暨南國際大學 資訊管理學系

智慧型釣魚網站偵測系統

網址機器學習與 HTML 網頁分析

第十組　113213021 陳昱維　113213065 謝承道　113213069 蘇資晉　113213076 王志騰

目錄

資料集與特徵.....03

模型訓練 & 評估.....07

HTML 分析.....13

網頁Demo.....19

期末規劃.....24

釣魚網站可以從哪裡觀察

只有一條網址

長度、子網域、符號與關鍵字

合法網址也可能有複雜路徑

先用字串特徵做初步分類

拿到 HTML 原始碼

查看表單送往哪個主機

檢查 iframe、密碼欄位與跳轉

把模型分數和靜態警示一起看

兩個入口依使用者手上已有的資料分別分析。

系統架構與四個頁面

離線模型與結果

URL 清理、切分與特徵萃取

URL 三模型訓練與評估

用 UCI 預先計算特徵做 HTML 消融

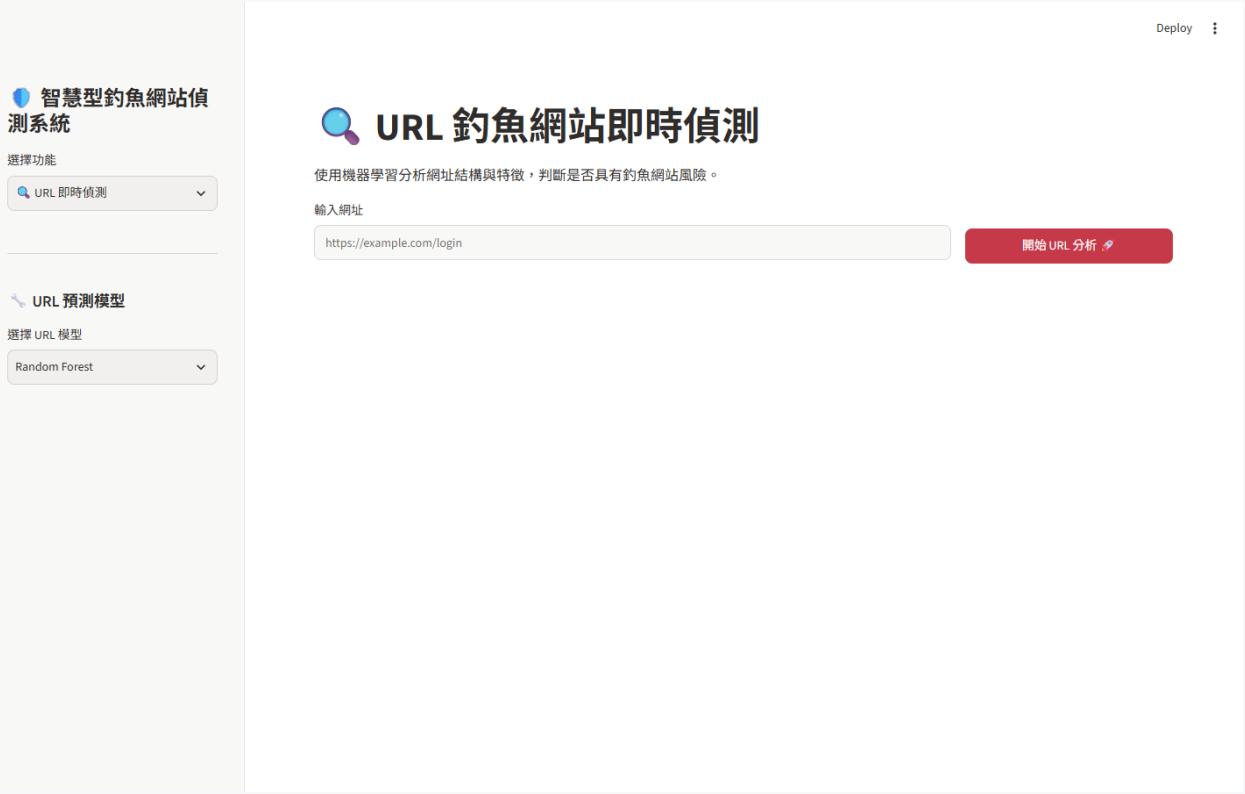
Streamlit 操作介面

URL 即時偵測

HTML 網頁安全分析

模型效能與實驗比較

專案介紹



URL 資料清理與分層切分

原始資料集共 549,346 筆，去重、清理空值與長度後，每類取前 5,000 筆再打散

7,000
訓練集 70%

1,500
驗證集 15%

1,500
測試集 15%

各資料切分的正常與釣魚樣本維持 1 比 1

現行訓練腳本讀取訓練集與測試集特徵檔。驗證集另行保留。

URL 的 17 個字串特徵

只讀取網址字串，即可計算所有欄位。

長度與結構 8 項	網址長度、網域長度、子網域數，以及 5 種符號次數
字元比例 2 項	數字比例、非英數字元比例
協議與 IP 2 項	是否使用 HTTPS、是否偵測到 IPv4 格式
關鍵字 5 項	login、verify、secure、account、update

範例 https://a.b.example.com/login-verify?id=123&account=update

四種分類方法：模型如何判斷釣魚網站？

前三種是機器學習模型；規則基準則依照開發者預先設定的條件進行判斷。

01 隨機森林 Random Forest

多棵決策樹各自進行判斷，再整合預測結果（多數決）。

優點：能整合多個模型的判斷，通常有較穩定的預測表現。

02 決策樹 Decision Tree

依照特徵條件逐層分割資料，沿著分支得到最後的分類結果。

優點：判斷路徑清楚，較容易解釋分類原因。

03 邏輯斯迴歸 Logistic Regression

將各項特徵加權計算，估計屬於釣魚類別的機率，再依門檻分類。

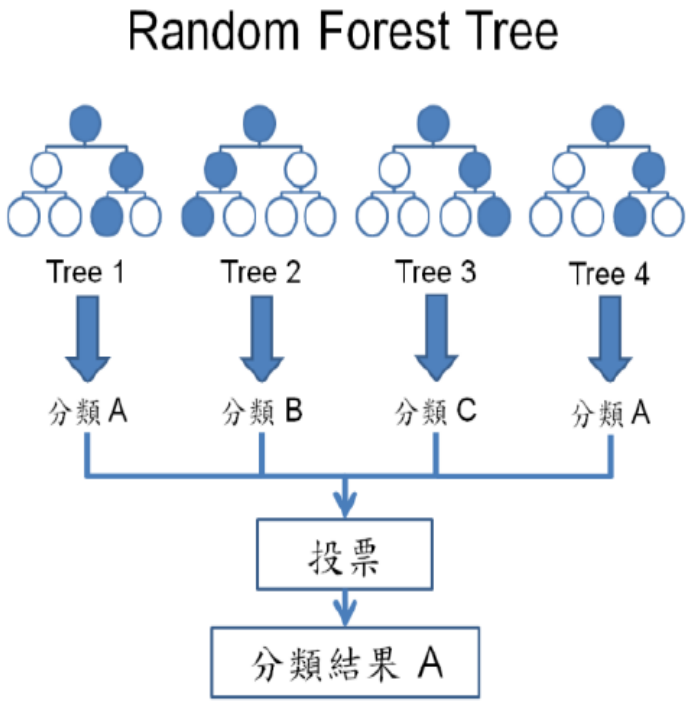
優點：模型較簡單、運算快速，也能檢視特徵權重。

04 人工規則 Rule-based

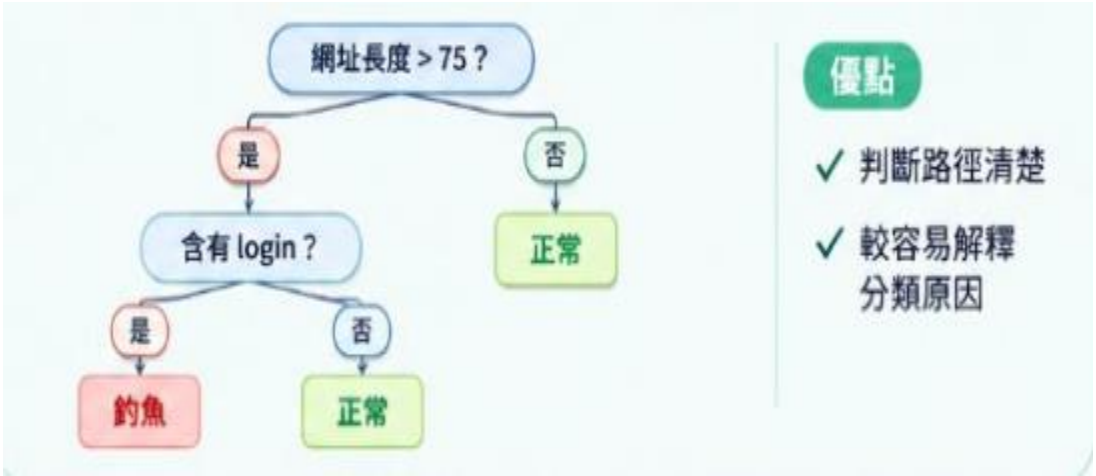
由開發者預先設定條件並累積分數；本專題總分 ≥ 3 判為釣魚。

特色：不需訓練模型，但辨識效果受規則完整度限制。

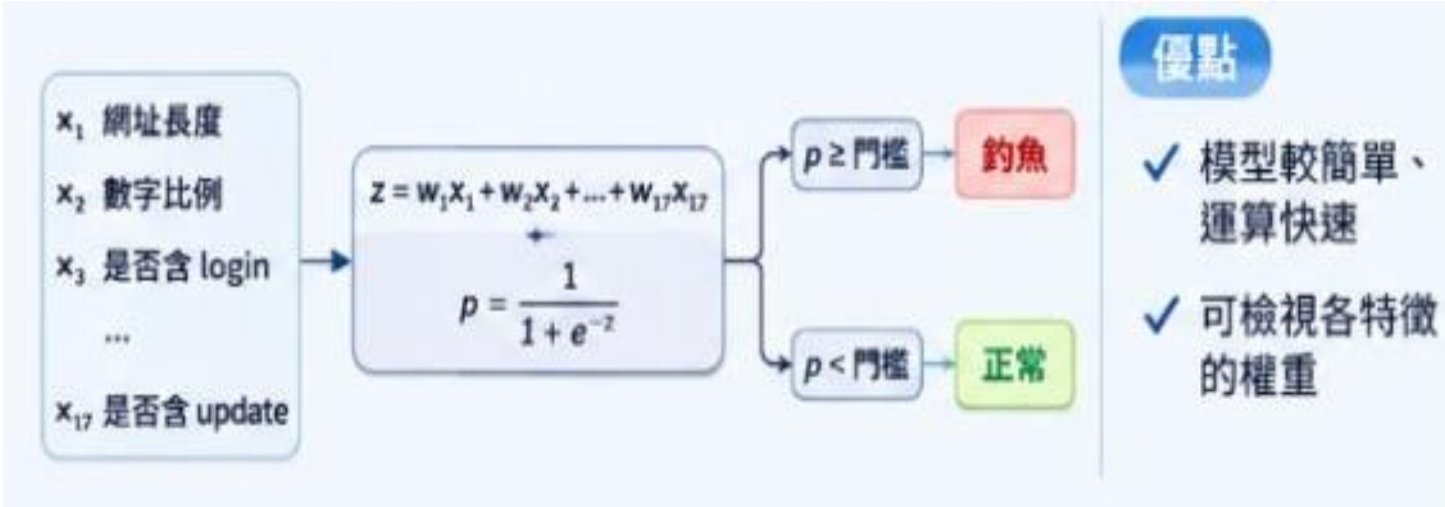
比較方式：三種機器學習模型使用相同的 17 個 URL 特徵；規則基準另以獨立腳本評估。



多顆決策樹自行判斷，最後在整合結果



依照特徵條件逐層分割資料，沿著分支得到最後的分類結果



將各項特徵加權計算，估計屬於釣魚類別的機率，再依門檻分類。



由開發者預先設定條件並累積分數；總分 ≥ 3 判為釣魚。

URL 評估

URL 模型測試結果

測試集共 1,500 筆（正常 750、釣魚 750），本次以釣魚網站為正類。

模型	準確率	精確率	召回率	F1
隨機森林	**88.80%**	**89.75%**	**87.60%**	**88.66%**
決策樹	86.93%	88.26%	85.20%	86.70%
邏輯斯迴歸	76.33%	84.47%	64.53%	73.17%
規則基準	57.07%	97.32%	14.53%	25.29%

規則基準的 112 次警報有 109 次命中，但只找到 750 筆釣魚中的 109 筆。

URL 評估

隨機森林的誤報與漏判

混淆矩陣以真實類別為列，預測類別為欄。

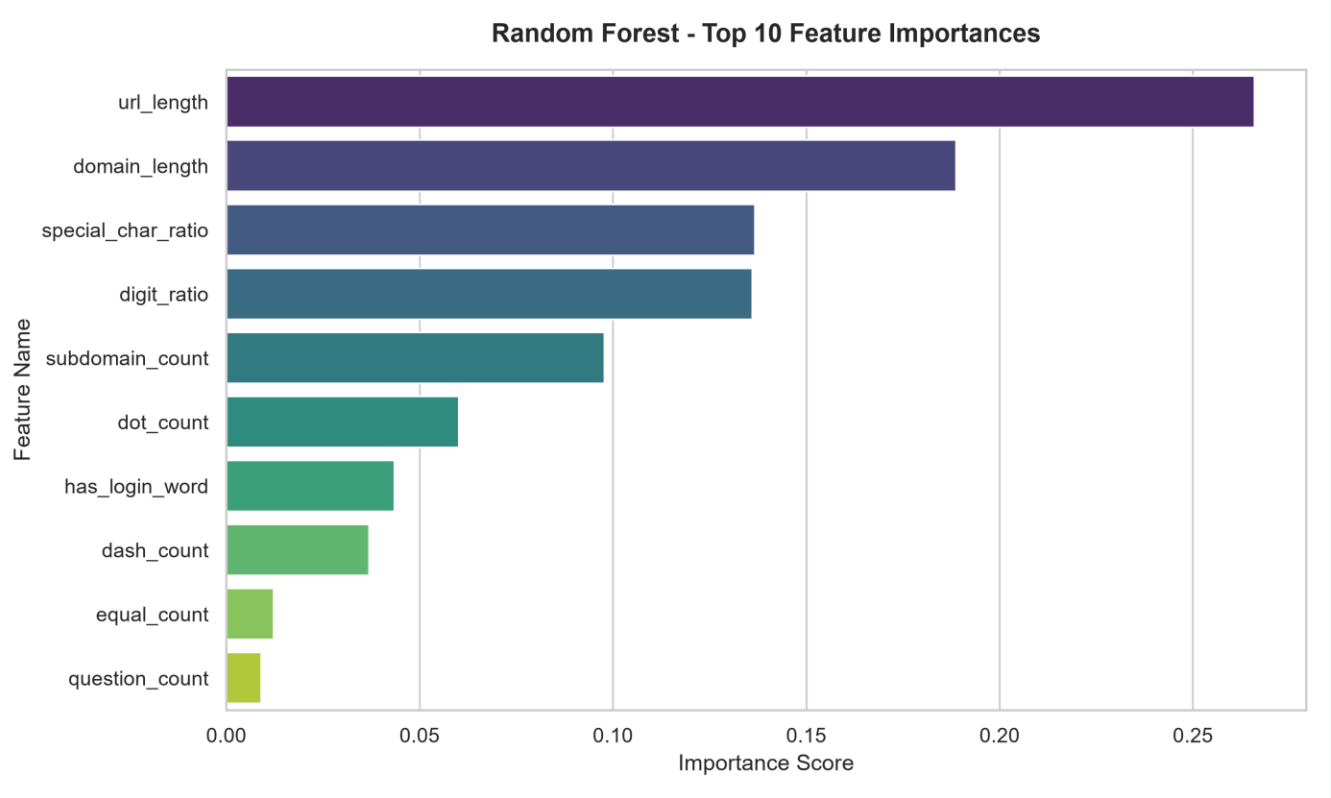
真實類別	預測正常	預測釣魚
正常 750 筆	675 正確	75 誤報
釣魚 750 筆	93 漏判	657 正確

10.0% 正常樣本誤報率

12.4% 釣魚樣本漏判率

以 1,500 筆為分母時，誤報占全體 5.0%，漏判占全體 6.2%。

URL 特徵重要度與錯誤案例



可能的誤報

合法登入頁有長路徑

正常業務包含 login 或 verify

可能的漏判

釣魚網址短、字元單純

單靠字串較難區分

重要度反映模型整體使用特徵的情況。

HTML 網頁安全分析流程

01 提供 HTML 上傳 .html 或 .htm，或貼上原始碼。上限 2 MB。

02 填原始網站網址 解析表單相對路徑，並與目的地主機比較。

03 執行分析 同時跑兩個 HTML 模型，並檢查可疑結構。

04 查看報告 預測、基本特徵、警示、表單分析及 JSON 匯出。

系統解析提供的 HTML 文字，原始網站網址用於解析與比對。

HTML 模型的五個共用特徵

欄位	型態	用於
標題、提交按鈕、隱藏欄位、密碼欄位	各自為有或無	兩個模型
iframe 數量	計數	兩個模型
圖片數量	**計數**	**六特徵模型**

六特徵模型多讀取一個欄位 NoOfImage。

HTML 靜態檢查與表單報告

檢查項目

隱藏 iframe

跨網域表單

跨網域密碼表單

Meta Refresh 自動跳轉



表單分析另列出送出目的地。JavaScript 執行時生成的元素超出靜態檢查範圍。

HTML 五特徵與六特徵的實驗設計

資料來源為 UCI PhiUSIIL，使用資料集預先計算的欄位。

235,795
資料集總筆數

47,159
共用測試集筆數

120
每個隨機森林的樹數

分層切分為 80% 訓練、20% 測試

相同資料與模型設定，對照有無圖片數量欄位

實驗把 UCI 的原始標籤轉為 1 表示釣魚、0 表示正常。

HTML 消融結果與錯誤件數

模型	準確率	精確率	召回率	F1
六特徵	96.34%	95.87%	95.56%	95.71%
五特徵	86.63%	82.05%	88.03%	84.94%

+9.71 個百分點

六特徵較五特徵的準確率差

漏判 2,417 降至 896
誤報 3,887 降至 832

指標取自 UCI 預先計算的特徵。新 HTML 的端到端表現需另行驗證。

模型分數與靜態警示的解讀

URL 模型分數	對應模型選出的類別，可能是正常，也可能是釣魚。
HTML 模型分數	固定呈現釣魚類別分數，兩欄可以並排解讀。
HTML 靜態警示	指出觸發的結構或表單，便於回頭檢查原始碼。

分數的實務風險意義需要另做校準。

實機示範

git clone https://github.com/kcwj20051226-cyber/phishing-url-project.git

cd phishing-url-project

pip install pandas numpy scikit-learn joblib streamlit matplotlib seaborn

python -m streamlit run app/streamlit_app.py

https://github.com/JPCERTCC/phishurl-list/blob/main/2026/202609.csv

實機示範一 URL 即時偵測

用Random Forest模型　輸入 https://example.com/



92.67%

正常類別模型分數

可展開 17 項
URL 特徵詳情

實機示範二 HTML 網頁安全分析

同一份 HTML 含隱藏 iframe 與跨網域密碼表單。



下方報告

核對靜態警示

查看表單目的地

下載 JSON

模型效能頁與專案介紹

📊 模型效能與實驗比較

🌐 URL 模型效能

	Model	Accuracy	Precision	Recall	F1-score
0	Decision Tree	0.8693	0.8826	0.852	0.867
1	Random Forest	0.888	0.8975	0.876	0.8866
2	Logistic Regression	0.7633	0.8447	0.6453	0.7317

🧩 HTML 特徵消融實驗

	Model	Features	Accuracy	Precision_Phishing	Recall_Phishing	F1_Phishing	False_Negatives	False_Positives	True_Negatives
0	Six features	6	0.9634	0.9587	0.9556	0.9571	896	832	26138
1	Five features (no image)	5	0.8663	0.8205	0.8803	0.8494	2417	3887	23083

📈 五特徵與六特徵效能比較



模型效能頁

URL 模型表與原始圖表

HTML 消融結果與長條圖

專案介紹

系統目標、各模組與團隊

專案成果

URL 模組提供網址分類與 17 項特徵。

HTML 模組提供模型預測、靜態警示與可匯出的報告。

期末目標

1.引進進階集成演算法

2.實施模型集成與融合，降低誤判率

3.針對誤判與漏判進行特徵優化,ex白名單

4.完整技術手冊與專案報告書

5.開發輕量級瀏覽器外掛，展示即時攔截

分工表

組員	項目
謝承道	資料集與特徵處理
蘇資晉	模型訓練
王志騰	HTML網頁分析
陳昱維	網站架設Demo


謝謝大家